



**UNIVERSITÀ
DEGLI STUDI
DI UDINE**
HIC SUNT FUTURA

DIPARTIMENTO DI SCIENZE MATEMATICHE, INFORMATICHE E FISICHE

TESI DI LAUREA IN
INFORMATICA

Utilizzo di telecamere in ambienti industriali reali

CANDIDATO

Michele Ongaro

RELATORE

Prof. Agostino Dovier

TUTOR AZIENDALE

Ing. Umberto Piconi

Anno accademico 2025-2026

CONTATTI DELL'ISTITUTO

Dipartimento di Scienze Matematiche, Informatiche e Fisiche

Università degli Studi di Udine

Via delle Scienze, 206

33100 Udine — Italia

+39 0432 558400

<https://www.dmif.uniud.it/>

Indice

1	Introduzione	1
1.1	Obiettivi	1
1.2	Presentazione dello scenario applicativo	1
1.3	Considerazioni implementative	3
2	Sviluppo delle metriche	5
2.1	Metriche basate sull'analisi delle frequenze	6
2.1.1	Fourier	7
2.1.2	Skewness	9
2.2	Metriche basate sull' <i>edge detection</i>	13
2.2.1	Laplacian	14
2.2.2	Canny	15
2.3	Altre metriche	17
3	Definizione dei threshold	19
3.1	Calcolo del threshold	19
3.2	Considerazioni sulla risoluzione delle immagini	21
4	Valutazione e confronto delle metriche	23
5	Conclusioni e considerazioni finali	25

1

Introduzione

1.1 Obiettivi

L'obiettivo del presente lavoro è sviluppare un algoritmo in grado di determinare automaticamente lo stato di pulizia dell'obiettivo di una telecamera, identificando eventuali condizioni di sporco o ostruzione attraverso l'analisi delle immagini acquisite. Le immagini considerate provengono da un flusso video generato da un insieme di telecamere IP installate in prossimità di specifiche targhe (*plate*). Ciascuna targa riporta un codice visivo progettato secondo una codifica di Hamming, che ne garantisce la riconoscibilità e la robustezza rispetto a errori di lettura. L'idea alla base dell'algoritmo è sfruttare la presenza di tali targhe come riferimento noto all'interno della scena. Analizzando la qualità con cui il codice viene acquisito e decodificato dalle immagini, è possibile ricavare indicatori utili a valutare le condizioni dell'obiettivo. Fenomeni quali accumulo di polvere, sporco, gocce d'acqua o altre ostruzioni tendono infatti a degradare la qualità dell'immagine, riducendo la nitidezza e aumentando gli errori nella rilevazione del codice. Il sistema dovrà quindi elaborare i frame del flusso video e produrre una classificazione dello stato della telecamera, distinguendo tra condizioni operative normali e situazioni in cui l'obiettivo risulta sufficientemente sporco da compromettere l'affidabilità dell'acquisizione e della successiva lettura del codice.

1.2 Presentazione dello scenario applicativo

L'infrastruttura aziendale considerata è costituita da un insieme di telecamere IP installate in posizioni strategiche all'interno dell'impianto produttivo. Tali telecamere sono orientate verso delle cisterne contenenti materiale metallico fuso e hanno il compito di monitorarne il movimento e l'identificazione. Ogni cisterna è dotata di una targa (*plate*) sulla quale è riportato un codice opportunamente progettato per essere riconosciuto automaticamente da un sistema di visione artificiale. Le telecamere trasmettono continuamente le immagini acquisite mediante protocollo RTSP (*Real Time Streaming Protocol*) ad una pipeline di elaborazione dedicata al riconoscimen-

to dei codici presenti sui *plate*. La pipeline è composta da diversi livelli di elaborazione che, partendo dall'immagine acquisita, eseguono una serie di operazioni finalizzate all'individuazione del codice e alla sua successiva decodifica. Al termine del processo viene restituito il valore numerico associato alla targa osservata. Non sempre, tuttavia, la pipeline riesce a completare correttamente il processo di riconoscimento. Le cause di un fallimento possono essere molteplici e non necessariamente legate a malfunzionamenti del sistema di visione. Una prima causa è rappresentata dall'assenza del *plate* all'interno della porzione di immagine analizzata. Infatti, per motivi di efficienza e configurabilità, il sistema di riconoscimento può essere impostato per elaborare esclusivamente una specifica regione dell'immagine originale (*Region of Interest*, ROI). Di conseguenza, se il *plate* si trova al di fuori di tale area oppure non è visibile nell'inquadratura in quel determinato istante, la pipeline non dispone delle informazioni necessarie per effettuare la decodifica. Una seconda categoria di problematiche riguarda invece la qualità dell'immagine acquisita. Condizioni di illuminazione non adeguate, errori di messa a fuoco, movimenti della cisterna, presenza parziale del *plate* nell'inquadratura o una dimensione insufficiente dello stesso all'interno dell'immagine possono compromettere significativamente le prestazioni dell'algoritmo di riconoscimento. In tali situazioni il codice risulta difficilmente distinguibile e il livello di affidabilità richiesto dalla decodifica non può essere garantito. Particolare interesse riveste un'ulteriore causa di degrado delle prestazioni, ovvero la presenza di sporco sull'obiettivo della telecamera. Durante le normali operazioni dell'impianto può accadere che il materiale metallico fuso generi schizzi che raggiungono la superficie dell'obiettivo, depositandosi su di essa. La presenza di tali impurità altera la qualità delle immagini prodotte, introducendo sfocature, appannamenti, zone opache e riduzioni del contrasto che rendono più difficile il riconoscimento del codice.

Poiché il sistema di decodifica opera imponendo una soglia minima di affidabilità, il degrado della qualità visiva può portare la pipeline a rifiutare il risultato della lettura, producendo un esito negativo anche quando il *plate* è effettivamente presente e correttamente inquadrato. In questi casi il mancato riconoscimento non dipende dall'assenza del codice, ma esclusivamente dalle condizioni non ottimali del sistema di acquisizione. Per questo motivo risulta particolarmente utile disporre di un indicatore indipendente dalla presenza o meno del *plate* all'interno dell'immagine, capace di fornire una valutazione oggettiva dello stato dell'obiettivo della telecamera. Un tale indicatore consentirebbe di individuare tempestivamente situazioni di degrado della qualità delle immagini e di programmare interventi di manutenzione prima che il problema influisca significativamente sul processo produttivo. L'obiettivo finale è quindi quello di realizzare un sistema in grado di monitorare automaticamente le condizioni dell'obiettivo e segnalare eventuali anomalie dovute alla presenza di sporco. In questo modo sarebbe possibile ridurre i periodi di inattività della pipeline di riconoscimento, migliorando l'affidabilità complessiva del sistema e garantendo una maggiore continuità operativa.

1.3 Considerazioni implementative

Le telecamere impiegate nell'infrastruttura sono configurate per gestire automaticamente la messa a fuoco dell'immagine. Tale funzionalità consente normalmente di mantenere nitida la scena osservata anche in presenza di variazioni della distanza tra la telecamera e gli oggetti inquadrati.

Dalle osservazioni effettuate sul campo è emerso tuttavia un comportamento ricorrente quando l'obiettivo viene colpito da schizzi di materiale metallico fuso. In queste situazioni la telecamera tende a considerare la macchia depositata sulla superficie dell'obiettivo come nuovo punto di riferimento per il sistema di autofocus. Di conseguenza, la messa a fuoco viene regolata sulla macchia stessa anziché sugli elementi presenti nella scena osservata. Questo fenomeno produce un evidente degrado della qualità dell'immagine: la porzione di sporco risulta relativamente nitida mentre il resto della scena appare fortemente sfocato. In tali condizioni la pipeline di riconoscimento dei codici non è più in grado di garantire il livello di affidabilità richiesto, poiché le informazioni necessarie alla corretta individuazione e decodifica del *plate* risultano degradate.

Alla luce di queste osservazioni, lo studio presentato in questo lavoro si concentra esclusivamente sull'analisi del grado di nitidezza delle immagini acquisite. L'ipotesi di partenza è che la perdita di fuoco rappresenti il principale effetto osservabile della presenza di sporco sull'obiettivo e che, di conseguenza, possa essere utilizzata come indicatore indiretto dello stato della telecamera. L'obiettivo dell'algoritmo non è quindi quello di rilevare direttamente la presenza di macchie o impurità sull'obiettivo, bensì quello di distinguere tra immagini nitide e immagini sfocate. Una classificazione affidabile di tali condizioni consentirebbe infatti di individuare automaticamente le situazioni in cui la telecamera non opera più nelle condizioni ottimali previste. In particolare, qualora l'algoritmo determini che un'immagine risulta significativamente sfocata, tale informazione potrà essere interpretata come un forte indicatore di una perdita di corretta messa a fuoco. Nel contesto applicativo considerato, e sulla base delle evidenze raccolte, questa situazione è associata con elevata probabilità alla presenza di sporco sull'obiettivo causato dagli schizzi di metallo provenienti dalle cisterne monitorate.

La tesi è organizzata come segue: nel capitolo 2 si presenteranno diverse soluzioni di tipo algoritmico che permetteranno di ottenere una metrica che stabilisce il livello di sfocatura di una immagine, nel capitolo 3 si spiegherà come sia possibile ottenere dei valori di limite utili alla creazione di un sistema decisionale che distingue immagini sfocate da immagini nitide, nel capitolo 4 si effettuerà un confronto tra le varie metriche e si cercherà di stabilire quale sia quella migliore per questo specifico dominio applicativo, infine nel capitolo 5 si troveranno le conclusioni sul lavoro svolto insieme alla definizione del test di cui il classificatore farà uso.

2

Sviluppo delle metriche

La determinazione del grado di nitidezza di un'immagine rappresenta un problema ampiamente studiato nell'ambito dell'*image processing* e della visione artificiale. Nel corso degli anni sono state proposte numerose tecniche per stimare la qualità visiva di un'immagine e, più in particolare, per individuare la presenza di fenomeni di sfocatura che possono compromettere le prestazioni dei sistemi di riconoscimento automatico. Nel contesto di questo lavoro, l'obiettivo è individuare un insieme di metriche in grado di fornire una misura quantitativa della nitidezza delle immagini acquisite dalle telecamere. Tali metriche dovranno successivamente essere utilizzate per discriminare tra immagini che presentano condizioni di acquisizione corrette e immagini che risultano degradate a causa di una perdita di messa a fuoco. Le tecniche più diffuse per affrontare questo problema possono essere ricondotte a due grandi categorie. La prima comprende le **metriche basate sull'analisi delle frequenze**, mentre la seconda raccoglie le **metriche basate sull'individuazione dei bordi** (*edge detection*).

Le metriche appartenenti alla prima categoria approfondite nella sezione 2.1 sfruttano il fatto che un'immagine nitida contiene generalmente una maggiore quantità di dettagli ad alta frequenza. Quando l'immagine diventa sfocata, tali dettagli tendono a scomparire e il contenuto in alta frequenza si riduce. Analizzando quindi la distribuzione delle frequenze presenti nell'immagine è possibile ottenere una stima del suo livello di nitidezza.

Le metriche basate sull'*edge detection* approfondite nella sezione 2.2 invece, si fondano sull'osservazione che un'immagine ben focalizzata presenta contorni e transizioni di intensità particolarmente marcati. Al contrario, la sfocatura tende ad attenuare tali variazioni rendendo i bordi meno definiti. Misurando la quantità dei bordi rilevati è quindi possibile ricavare informazioni utili sul grado di messa a fuoco dell'immagine.

Sebbene queste due categorie rappresentino gli approcci maggiormente utilizzati in letteratura, non esauriscono tutte le possibili tecniche disponibili. Esistono infatti ulteriori metriche che analizzano altre proprietà statistiche o strutturali dell'immagine e che possono fornire informazioni complementari sulla sua qualità visiva. Nella sezione 2.3 verranno quindi esaminate diverse metodologie, evidenziandone i principi di funzionamento, i vantaggi e i limiti nel contesto

applicativo considerato.

Prima di applicare una qualsiasi delle metriche descritte, le immagini vengono sottoposte ad una fase preliminare di *preprocessing*. Lo scopo di questa fase è ridurre l'influenza di fattori esterni che potrebbero alterare il risultato delle misurazioni e rendere meno confrontabili immagini acquisite in condizioni differenti. In particolare, il processo di *preprocessing* adottato prevede due operazioni principali. La prima consiste nella normalizzazione della luminosità dell'immagine, necessaria per limitare gli effetti dovuti a variazioni delle condizioni di illuminazione della scena. La seconda consiste nella conversione dell'immagine dalla rappresentazione a colori alla scala di grigi. Questa trasformazione consente di ridurre la complessità computazionale dell'elaborazione e di concentrare l'analisi esclusivamente sulle variazioni di intensità luminosa, che costituiscono l'informazione maggiormente rilevante per la stima della nitidezza. Una volta completata questa fase preliminare, l'immagine quindi risulta pronta per l'applicazione delle diverse metriche che verranno descritte nelle sezioni successive.

2.1 Metriche basate sull'analisi delle frequenze

Uno degli approcci più utilizzati per valutare il grado di nitidezza di un'immagine consiste nell'analizzarne il contenuto in frequenza. Questo metodo si basa sull'idea che un'immagine possa essere interpretata come un segnale bidimensionale discreto, nel quale a ciascuna coppia di coordinate spaziali è associato un valore di intensità luminosa. In maniera analoga a quanto avviene nell'elaborazione dei segnali monodimensionali, anche per le immagini è possibile studiare come l'informazione sia distribuita tra diverse componenti di frequenza. In questo contesto, il concetto di frequenza non è legato al tempo, bensì alla variazione spaziale dell'intensità dei pixel. Più precisamente, una variazione lenta e graduale dei livelli di grigio corrisponde a una componente a bassa frequenza, mentre variazioni rapide e localizzate corrispondono a componenti ad alta frequenza. Dal punto di vista visivo, le componenti a bassa frequenza descrivono principalmente la struttura generale dell'immagine, come le forme di grandi dimensioni e le variazioni graduali di luminosità. Le componenti ad alta frequenza, invece, rappresentano i dettagli più fini della scena, come i contorni degli oggetti, le texture e le transizioni nette tra regioni adiacenti. La sfocatura agisce proprio su queste componenti ad alta frequenza. Quando un'immagine perde nitidezza, i dettagli più fini tendono infatti ad attenuarsi o a scomparire completamente. Di conseguenza, il contenuto in alta frequenza si riduce mentre le componenti a bassa frequenza diventano predominanti. Questo comportamento rende possibile stimare il grado di messa a fuoco di un'immagine osservando come l'energia del segnale sia distribuita nello spettro delle frequenze. Per effettuare tale analisi è possibile utilizzare la Trasformata Discreta di Fourier (*Discrete Fourier Transform*, DFT), uno strumento matematico che consente di passare dal dominio spaziale al dominio delle frequenze. Applicando la DFT ad un'immagine si ottiene una rappresentazione alternativa del contenuto informativo, nella quale è possibile osservare direttamente le diverse componenti di

frequenza che contribuiscono alla formazione dell'immagine originale.

L'ipotesi alla base delle metriche presentate in questa sezione è quindi la seguente: un'immagine correttamente focalizzata possiede generalmente una maggiore quantità di componenti ad alta frequenza rispetto ad un'immagine sfocata. Analizzando opportunamente lo spettro ottenuto tramite la trasformata di Fourier è quindi possibile costruire un indice capace di discriminare tra immagini nitide e immagini degradate. Le metriche descritte nelle sezioni successive condividono entrambe questo principio di funzionamento e si basano sull'applicazione della Trasformata Discreta di Fourier. Esse differiscono tuttavia nel modo in cui lo spettro delle frequenze viene analizzato e nella particolare misura utilizzata per quantificare il contenuto informativo associato alle alte frequenze.

2.1.1 Fourier

La prima metrica considerata si basa sull'analisi dello spettro delle frequenze ottenuto tramite la Trasformata Discreta di Fourier (DFT) [6]. L'idea alla base di questo approccio è quella di valutare come l'energia dell'immagine sia distribuita tra le componenti a bassa e ad alta frequenza.

Come discusso nella sezione precedente, le immagini nitide tendono a contenere una quantità maggiore di componenti ad alta frequenza, associate alla presenza di dettagli, contorni e variazioni rapide di intensità. Al contrario, la sfocatura agisce come un filtro passa-basso, attenuando progressivamente tali componenti e concentrando gran parte dell'energia dell'immagine nelle frequenze più basse. Per effettuare questa analisi si applica innanzitutto la Trasformata Discreta di Fourier all'immagine pre-processata. Il risultato è una matrice di numeri complessi che rappresenta lo spettro delle frequenze dell'immagine. Ciascun elemento della matrice descrive il contributo di una specifica frequenza alla formazione dell'immagine originale. Dopo aver eseguito l'operazione di *shift* della trasformata, la componente a frequenza nulla (detta anche componente continua o *DC*) viene posizionata al centro della matrice. Procedendo radialmente verso l'esterno si incontrano frequenze via via più elevate. In altre parole, il centro della matrice rappresenta le basse frequenze, mentre le regioni periferiche contengono le componenti ad alta frequenza. Poiché i valori restituiti dalla trasformata sono numeri complessi, per ogni elemento viene calcolato il modulo. In questo modo si ottiene una matrice contenente esclusivamente valori reali positivi, comunemente indicata come *magnitude spectrum*. Tali valori rappresentano l'intensità con cui ciascuna frequenza contribuisce all'immagine. Una volta ottenuta la matrice dei moduli, si procede alla separazione delle frequenze basse da quelle alte. A tale scopo viene definita una regione circolare centrata nello spettro e avente raggio pari al 10% della dimensione minima tra altezza e larghezza dell'immagine. Tutte le frequenze contenute all'interno di questo cerchio vengono considerate basse frequenze, mentre tutte quelle esterne vengono considerate alte frequenze.

Indicando con Ω l'insieme di tutte le componenti della trasformata di Fourier e con Ω_{low} il sottoinsieme delle basse frequenze, viene definito il seguente indice:

$$\alpha = \frac{\sum_{f \in \Omega_{\text{low}}} \|f\|}{\sum_{f \in \Omega} \|f\|} \quad (2.1)$$

dove:

- α rappresenta il valore di sfocatura (*blur value*);
- Ω è l'insieme di tutte le componenti della trasformata di Fourier;
- Ω_{low} contiene esclusivamente le componenti associate alle basse frequenze;
- $\|f\|$ indica il modulo della componente complessa f .

L'indice α assume valori compresi tra 0 e 1 e può essere interpretato come la frazione di energia concentrata nelle basse frequenze. Quando l'immagine è nitida, una parte significativa dell'energia è distribuita anche nelle frequenze più elevate. In questo caso il denominatore risulta molto maggiore del numeratore e il valore di α tende ad assumere valori relativamente bassi. Al contrario, quando l'immagine è sfocata, il contenuto ad alta frequenza diminuisce sensibilmente e la maggior parte dell'energia si concentra nelle basse frequenze. Di conseguenza il numeratore e il denominatore assumono valori sempre più simili e l'indice α tende ad avvicinarsi a 1. Ne consegue che valori bassi di α sono generalmente associati ad immagini nitide, mentre valori elevati indicano una probabile perdita di messa a fuoco.

Lo pseudocodice riportato di seguito descrive l'implementazione della metrica.

```

1 def getBlurValue(image):
2     omega = fft(image)           # trasformata di fourier
3     magnitude = abs(omega)       # calcolo moduli
4     h, w = shape(magnitude)
5     cutoff = min(h, w) * 0.1    # limite per le basse frequenze
6
7     low = magnitude[where r < cutoff].sum()
8     high = magnitude[where r >= cutoff].sum()
9
10    return low / (high + low)

```

Le figure successive mostrano la rappresentazione della magnitude della trasformata di Fourier per due immagini caratterizzate da un diverso livello di nitidezza. Nel caso dell'immagine sfocata, gran parte dell'energia risulta concentrata nella regione centrale dello spettro. Questo comportamento indica una predominanza delle basse frequenze e una ridotta presenza di dettagli ad alta frequenza. Al contrario, nell'immagine nitida si osserva una distribuzione più ampia dell'energia anche nelle regioni periferiche della trasformata. La presenza di contributi significativi alle alte frequenze è infatti direttamente collegata alla presenza di dettagli e contorni ben definiti nella scena originale.




Figura 2.1: Magnitude della trasformata di Fourier per un'immagine sfocata. L'energia risulta prevalentemente concentrata nelle basse frequenze.




Figura 2.2: Magnitude della trasformata di Fourier per un'immagine nitida. Si osserva una maggiore presenza di componenti ad alta frequenza rispetto al caso precedente.

2.1.2 Skewness

Questa è la seconda metrica che si basa sull'analisi della distribuzione delle frequenze presenti nell'immagine. Fa uso di un indicatore statistico: l'indice di *skewness* [2]. Tale indice misura il grado di asimmetria di una distribuzione rispetto al proprio valore medio e consente quindi di descriverne la forma. L'idea alla base di questo approccio nasce dall'osservazione che la sfocatura non modifica solamente la quantità di energia presente nelle varie frequenze, ma altera anche il modo in cui tale energia è distribuita all'interno dello spettro di Fourier. In particolare, quando un'immagine diventa sfocata, una porzione sempre maggiore dell'energia tende a concentrarsi nelle frequenze più basse, mentre il contributo delle alte frequenze diminuisce progressivamente.

Per quantificare questo fenomeno si parte, come nel caso della metrica precedente, dalla Trasformata Discreta di Fourier dell'immagine. Dopo aver calcolato il modulo di ciascuna componente complessa, si ottiene la matrice delle magnitudini che rappresenta l'intensità delle diverse frequenze presenti nell'immagine. A questo punto non si effettua una semplice separazione tra frequenze basse e frequenze alte, ma si costruisce una vera e propria distribuzione delle frequenze. Per fare ciò vengono considerati una serie di cerchi concentrici centrati nella frequenza nulla, posta al centro dello spettro di Fourier. Ogni cerchio rappresenta una determinata distanza dal centro e quindi una specifica banda di frequenze. Per ciascun raggio viene calcolata la somma delle magnitudini appartenenti alla relativa corona circolare. Ripetendo questa operazione per tutti i raggi si ottiene una sequenza di valori che descrive come l'energia dell'immagine è distribuita al variare della frequenza. Dal punto di vista intuitivo, una distribuzione di questo tipo può essere interpretata come un istogramma radiale dello spettro di Fourier. I primi valori della sequenza rappresentano il contributo delle basse frequenze, mentre i valori successivi descrivono il contributo delle frequenze progressivamente più elevate. Una volta costruita la distribuzione, viene calcolato il coefficiente di *skewness*. Nel presente lavoro è stata utilizzata la formula di Pearson:

$$\text{Pearson's median skewness} = 3 \cdot \frac{\text{Mean} - \text{Median}}{\text{Standard deviation}} \quad (2.2)$$

Il valore ottenuto fornisce una misura dell'asimmetria della distribuzione. Un valore positivo indica una distribuzione *right-skewed*, ovvero caratterizzata da una coda estesa verso destra. Un valore negativo indica una distribuzione *left-skewed*, ovvero caratterizzata da una coda estesa verso sinistra. Un valore prossimo a zero indica una distribuzione sostanzialmente simmetrica. Nel caso delle immagini analizzate ci si aspetta generalmente una distribuzione *right-skewed*. Questo comportamento deriva dal fatto che le basse frequenze contribuiscono naturalmente in misura maggiore rispetto alle alte frequenze. Quando l'immagine diventa sfocata tale fenomeno si accentua ulteriormente, poiché una quota sempre più elevata dell'energia si concentra nelle regioni centrali dello spettro. Di conseguenza, la distribuzione associata ad un'immagine sfocata tende ad essere più asimmetrica rispetto a quella ottenuta da un'immagine nitida. In altre parole, all'aumentare della sfocatura ci si aspetta un incremento del coefficiente di *skewness*.

Le figure successive mostrano un esempio di distribuzione ottenuta per due immagini aventi differenti livelli di nitidezza. Nel caso dell'immagine sfocata si osserva una maggiore concentrazione dell'energia nelle frequenze più basse, che produce una distribuzione maggiormente sbilanciata verso destra. Nel caso dell'immagine nitida, invece, il contributo delle alte frequenze risulta più significativo e la distribuzione appare più equilibrata.




Figura 2.3: Distribuzione radiale delle magnitudini della trasformata di Fourier per un'immagine sfocata. La concentrazione dell'energia nelle basse frequenze genera una distribuzione fortemente *right-skewed*.




Figura 2.4: Distribuzione radiale delle magnitudini della trasformata di Fourier per un'immagine nitida. La presenza di contributi più elevati alle alte frequenze rende la distribuzione meno asimmetrica.

Poiché il coefficiente di *skewness* può assumere valori non limitati superiormente o inferiormente, risulta conveniente applicare una funzione di normalizzazione per ottenere un indice facilmente confrontabile tra immagini differenti. A tale scopo viene utilizzata una funzione sigmoide, che permette di trasformare il valore di *skewness* in un indice compreso nell'intervallo $[0, 1]$. In questo modo è possibile interpretare il risultato come un valore di sfocatura normalizzato, rendendo più semplice il confronto tra immagini diverse. Lo pseudocodice riportato di seguito descrive l'implementazione della metrica.

```

1 def getBlurValue(image):
2     omega = fft(image)
3     magnitude = abs(omega)
4     h, w = shape(fft)
5
6     radiusValues = []
7     for (radius = 1, radius < min(w,h), radius++):
8         radiusValues.push(magnitude[r == radius].sum())
9
10    mean = mean(radiusValues)
11    median = median(radiusValues)
12    std = std(radiusValues)
13    if std == 0:
14        return 1

```



```

15
16     skew = 3 * (mean - median) / std
17
18     return sigmoid(skew)

```

L'indice finale ottenuto dalla funzione sigmoide cresce all'aumentare dell'asimmetria della distribuzione e, di conseguenza, all'aumentare della predominanza delle basse frequenze. Valori elevati dell'indice sono quindi associati ad immagini potenzialmente sfocate, mentre valori più bassi indicano una distribuzione delle frequenze maggiormente compatibile con immagini nitide.

2.2 Metriche basate sull'*edge detection*

Un secondo approccio largamente utilizzato per valutare il grado di nitidezza di un'immagine consiste nell'analizzarne i bordi (*edges*). A differenza delle metriche presentate nella sezione precedente, che operano nel dominio delle frequenze, queste tecniche lavorano direttamente nel dominio spaziale e si concentrano sull'individuazione delle transizioni di intensità presenti nell'immagine. L'idea alla base di questo approccio è relativamente semplice. In un'immagine correttamente focalizzata i contorni degli oggetti appaiono generalmente ben definiti e le variazioni di luminosità tra regioni adiacenti risultano particolarmente marcate. Al contrario, quando un'immagine diventa sfocata, tali transizioni tendono ad essere smussate e distribuite su un numero maggiore di pixel. Di conseguenza, i bordi risultano meno netti e più difficili da individuare. Dal punto di vista matematico, un bordo può essere interpretato come una variazione significativa dell'intensità luminosa tra pixel vicini. Le tecniche di *edge detection* hanno proprio lo scopo di individuare queste variazioni e di quantificarne l'intensità. Maggiore è il numero di bordi rilevati e più elevate sono le variazioni associate ad essi, maggiore sarà generalmente il livello di dettaglio presente nell'immagine. La sfocatura introduce invece un effetto opposto. Quando l'immagine perde nitidezza, le differenze di intensità tra pixel adiacenti si attenuano progressivamente. Questo fenomeno comporta una riduzione del numero di bordi rilevabili e una diminuzione della loro intensità. Per tale motivo, molte metriche di stima della nitidezza utilizzano la quantità e la qualità dei bordi come indicatore dello stato di messa a fuoco dell'immagine. Un ulteriore vantaggio di questo tipo di approccio è rappresentato dalla sua interpretabilità. Mentre le metriche basate sull'analisi delle frequenze operano su una rappresentazione trasformata dell'immagine, le metriche basate sull'*edge detection* lavorano direttamente sugli elementi visivi che un osservatore umano associa intuitivamente alla nitidezza, ovvero contorni, dettagli e strutture ben definite. Nel contesto applicativo considerato, la presenza di sporco sull'obiettivo porta frequentemente il sistema di autofocus a mettere a fuoco la macchia presente sulla lente anziché la scena osservata. Il risultato è una perdita significativa dei dettagli e una conseguente attenuazione dei bordi presenti nell'immagine. Analizzare tali variazioni risulta quindi particolarmente efficace per discriminare tra immagini nitide e immagini degradate.

Le metriche descritte nelle sezioni successive si basano tutte su questo principio generale. Sebbene differiscano per il metodo utilizzato per individuare e quantificare i bordi, condividono la medesima ipotesi: un'immagine nitida presenta generalmente bordi più numerosi e più marcati rispetto ad un'immagine sfocata.

2.2.1 Laplacian

La prima metrica appartenente alla categoria delle tecniche basate sull'*edge detection* utilizza l'operatore di Laplace (*Laplacian*) [3]. Questo operatore è uno degli strumenti più diffusi nell'ambito dell'elaborazione delle immagini per l'individuazione di contorni e variazioni locali di intensità. L'idea alla base della metrica è che una perdita di nitidezza si manifesta principalmente attraverso una riduzione delle variazioni brusche di luminosità presenti nell'immagine. Quando un'immagine è correttamente focalizzata, i contorni degli oggetti risultano ben definiti e i valori di intensità possono cambiare rapidamente passando da un pixel al successivo. Al contrario, in un'immagine sfocata tali transizioni diventano più graduali e meno marcate.

L'operatore Laplacian consente di evidenziare proprio queste variazioni locali. Dal punto di vista matematico, esso calcola la seconda derivata spaziale dell'immagine, mettendo in risalto le regioni in cui l'intensità luminosa subisce cambiamenti significativi. Le aree uniformi tendono ad assumere valori prossimi allo zero, mentre i bordi e le strutture più definite producono valori di maggiore intensità. Applicando il filtro Laplacian ad un'immagine si ottiene quindi una nuova immagine nella quale i contorni risultano evidenziati. A questo punto è possibile analizzare la distribuzione dei valori ottenuti per ricavare una misura della nitidezza. Nel presente lavoro viene utilizzata la varianza dell'immagine filtrata come indicatore della quantità di dettagli presenti nella scena. La varianza misura infatti quanto i valori risultanti dal filtro siano dispersi rispetto al loro valore medio. Quando l'immagine è nitida, il filtro Laplacian produce generalmente valori molto differenti tra loro: le aree contenenti bordi generano risposte elevate, mentre le regioni uniformi producono valori prossimi allo zero. Questa elevata variabilità si traduce in una varianza elevata. Al contrario, quando l'immagine è sfocata, i contorni risultano attenuati e la risposta del filtro diventa più uniforme. I valori generati dal Laplacian tendono quindi ad essere meno dispersi e la varianza assume valori inferiori. La varianza della risposta del Laplacian può quindi essere interpretata come una misura diretta della quantità di dettagli presenti nell'immagine. Maggiore è la varianza, maggiore è la probabilità che l'immagine sia correttamente focalizzata. Per ottenere un indice che cresca all'aumentare della sfocatura viene utilizzato l'inverso della varianza:

$$\alpha = \frac{1}{\text{Var}(L)} \quad (2.3)$$

dove:

- L rappresenta l'immagine ottenuta applicando il filtro Laplacian;

- $\text{Var}(L)$ rappresenta la varianza dei valori dell'immagine filtrata;
- α rappresenta il valore di sfocatura (*blur value*).

Da questa definizione segue che:

- immagini nitide producono una varianza elevata e quindi un valore di α ridotto;
- immagini sfocate producono una varianza più bassa e quindi un valore di α maggiore.

Lo pseudocodice che implementa questa metrica è riportato di seguito.

```

1 def getBlurValue(image):
2     edges = laplacian(image)
3
4     if edges.var() == 0:
5         return 1
6
7     return 1 / edges.var()
```

Uno dei principali vantaggi di questa tecnica è la sua semplicità computazionale. Il calcolo del filtro Laplacian e della relativa varianza richiede infatti un numero limitato di operazioni e può essere eseguito rapidamente anche su flussi video in tempo reale. Per questo motivo la varianza del Laplacian rappresenta una delle metriche più utilizzate per la stima della nitidezza nelle applicazioni industriali e nei sistemi di visione artificiale, dove è spesso necessario ottenere una valutazione veloce dello stato di messa a fuoco dell'immagine.

2.2.2 Canny

La seconda metrica basata sull'*edge detection* utilizza l'algoritmo di Canny [4], uno dei metodi più noti e utilizzati per il rilevamento dei bordi nelle immagini digitali. Analogamente alla metrica basata sul Laplacian, anche questo approccio si fonda sull'ipotesi che la quantità e la qualità dei bordi presenti nell'immagine siano direttamente correlate al suo livello di nitidezza. L'algoritmo di Canny è stato progettato con l'obiettivo di individuare i contorni in modo robusto, riducendo al minimo l'influenza del rumore e massimizzando la precisione nella localizzazione dei bordi. A differenza del semplice operatore Laplacian, il metodo di Canny non si limita ad applicare un singolo filtro, ma prevede una sequenza di elaborazioni che consentono di ottenere una mappa dei bordi particolarmente pulita e accurata.

La prima fase dell'algoritmo consiste nell'applicazione di un filtro Gaussiano all'immagine. Questa operazione ha lo scopo di ridurre il rumore presente nell'acquisizione ed eliminare le variazioni di intensità dovute a fenomeni non significativi. In termini di frequenze, il filtro Gaussiano attenua le componenti ad alta frequenza associate al rumore, preservando le strutture principali dell'immagine. Successivamente viene calcolato il gradiente dell'immagine mediante un operatore di derivata spaziale, tipicamente il filtro di Sobel [5]. Il gradiente misura la rapidità

con cui varia l'intensità luminosa tra pixel adiacenti e permette di individuare le regioni nelle quali sono presenti transizioni significative. Tali regioni corrispondono generalmente ai contorni degli oggetti presenti nella scena. L'immagine ottenuta dal calcolo del gradiente presenta delle strutture che possono essere interpretate come delle creste (*ridges*), ovvero zone in cui il modulo del gradiente assume valori elevati. Tuttavia, queste creste possono avere uno spessore di diversi pixel e non identificano ancora in modo preciso il bordo. Per ottenere contorni più sottili e accurati, l'algoritmo applica una fase denominata *non-maximum suppression*. Durante questa operazione vengono mantenuti soltanto i pixel che rappresentano un massimo locale lungo la direzione del gradiente, mentre tutti gli altri vengono posti a zero. Il risultato è una mappa dei bordi molto più precisa, nella quale i contorni appaiono ridotti ad una singola linea di pixel. Nella formulazione completa dell'algoritmo di Canny sono normalmente presenti ulteriori passaggi, come il *double thresholding* e l'*edge tracking by hysteresis*, che consentono di distinguere i bordi più affidabili da quelli potenzialmente generati dal rumore. Dal punto di vista della metrica di nitidezza, ciò che interessa è però principalmente l'immagine finale contenente i bordi rilevati.

Una volta ottenuta la mappa dei contorni, il principio utilizzato è del tutto analogo a quello adottato per la metrica Laplacian. Viene infatti calcolata la varianza dell'immagine risultante, assumendo che una maggiore dispersione dei valori sia indicativa di una maggiore presenza di dettagli e quindi di una migliore messa a fuoco. Nel caso di un'immagine nitida, il rilevatore di Canny individua generalmente un numero elevato di contorni ben definiti. La presenza di tali strutture produce una distribuzione dei valori maggiormente dispersa e quindi una varianza più elevata. Quando invece l'immagine è sfocata, le transizioni di intensità risultano attenuate e molti bordi non vengono più rilevati. L'immagine risultante contiene quindi meno informazioni strutturali e la varianza tende a diminuire. Per ottenere un indice che cresca all'aumentare della sfocatura, viene utilizzato l'inverso della varianza:

$$\alpha = \frac{1}{\text{Var}(C)} \quad (2.4)$$

dove:

- C rappresenta l'immagine ottenuta dall'algoritmo di Canny;
- $\text{Var}(C)$ rappresenta la varianza della mappa dei bordi;
- α rappresenta il valore di sfocatura (*blur value*).

Da questa definizione segue che immagini nitide producono una varianza elevata e quindi un valore di α ridotto mentre immagini sfocate producono una varianza più bassa e quindi un valore di α maggiore. Nel caso limite in cui la varianza sia nulla, significa che l'immagine risultante non contiene alcuna informazione utile sui bordi. Tale situazione può verificarsi in presenza di immagini estremamente degradate o uniformi. In questo caso la metrica restituisce direttamente il valore massimo di sfocatura.

Lo pseudocodice che implementa questa metrica è il seguente:

```

1 def getBlurValue(image):
2     edges = canny(image)
3
4     if edges.var() == 0:
5         return 1
6
7     return 1 / edges.var()

```

Rispetto alla metrica basata sul Laplacian, questo approccio presenta il vantaggio di utilizzare una procedura di rilevamento dei bordi più sofisticata e meno sensibile al rumore. La presenza della fase di smoothing iniziale e dei successivi passaggi di selezione dei contorni consente infatti di ottenere una rappresentazione più accurata delle strutture significative dell'immagine. Per tale motivo, la varianza dell'immagine prodotta dall'algoritmo di Canny può rappresentare un indicatore particolarmente efficace del livello di nitidezza, soprattutto in contesti reali nei quali le immagini possono essere affette da rumore, variazioni di illuminazione o altre sorgenti di degrado.

2.3 Altre metriche

Oltre agli approcci basati sull'analisi delle frequenze e sulle tecniche di *edge detection*, esistono ulteriori metodi che possono essere utilizzati per stimare in modo approssimativo il livello di sfocatura di un'immagine. Questi metodi si basano su osservazioni indirette della struttura dell'immagine e, pur essendo generalmente più semplici dal punto di vista computazionale, possono fornire informazioni utili in contesti applicativi specifici.

Una prima metrica alternativa si basa sulla dimensione in byte dei file JPEG [1]. L'idea alla base di questo approccio deriva direttamente dal funzionamento dell'algoritmo di compressione JPEG, che sfrutta la trasformata in frequenza per rappresentare l'immagine in modo più compatto eliminando le informazioni meno rilevanti dal punto di vista percettivo. In particolare, la compressione JPEG tende a ridurre maggiormente le componenti ad alta frequenza, che corrispondono ai dettagli fini, ai bordi e alle variazioni rapide di intensità. Poiché la sfocatura riduce proprio questo tipo di informazioni, un'immagine sfocata contiene generalmente meno dettagli ad alta frequenza rispetto ad una immagine nitida. Di conseguenza, durante il processo di compressione, un'immagine sfocata richiede una minore quantità di informazione per essere rappresentata, risultando spesso in un file di dimensioni inferiori rispetto ad un'immagine nitida con la stessa risoluzione. Questo fenomeno può essere sfruttato per costruire una metrica molto semplice, basata esclusivamente sulla dimensione del file JPEG. Tuttavia, è importante sottolineare che questa strategia è particolarmente sensibile a diversi fattori non direttamente legati alla nitidezza. La dimensione di un'immagine JPEG dipende infatti anche da elementi come la complessità cromatica della scena, la presenza di texture, il livello di rumore, le impostazioni di compressione utilizzate e la distribuzione dei dettagli all'interno dell'immagine. Per questo

motivo, due immagini entrambe nitide possono presentare dimensioni significativamente diverse, rendendo questa metrica meno robusta rispetto ad altre tecniche basate sull'analisi diretta del contenuto visivo. Nel grafico seguente viene riportato l'andamento della dimensione di un'immagine JPEG con risoluzione 640x480 sottoposta progressivamente a un processo di sfocatura mediante l'applicazione di un kernel di dimensione crescente. Come si può osservare, all'aumentare della sfocatura la dimensione del file tende a diminuire in modo progressivo, confermando l'intuizione alla base della metrica.




Figura 2.5: Andamento della dimensione di un'immagine JPEG al crescere del livello di sfocatura applicato.

Un'ulteriore metrica, concettualmente più semplice ma altrettanto intuitiva, consiste nell'analisi della varianza dei valori dei pixel dell'immagine. Un'immagine digitale può essere infatti rappresentata come una matrice bidimensionale di valori numerici, ciascuno dei quali corrisponde all'intensità luminosa (o ai valori dei canali cromatici) di un pixel. La varianza di questa distribuzione misura quanto i valori dei pixel si discostano dalla loro media. Nel caso di un'immagine completamente uniforme, tutti i pixel assumono lo stesso valore e la varianza risulta pari a zero. Questa situazione rappresenta un caso limite di assenza totale di informazione visiva, tipico di immagini completamente sfocate o uniformi. Al contrario, quando un'immagine contiene numerosi dettagli, bordi e variazioni di intensità, i valori dei pixel risultano più eterogenei e la varianza aumenta. In questo senso, la varianza globale dell'immagine può essere interpretata come un indicatore indiretto della quantità di informazione visiva presente. Sebbene questa metrica sia estremamente semplice da calcolare, essa presenta anch'essa alcune limitazioni. In particolare, non distingue tra variazioni dovute a dettagli significativi e variazioni causate da rumore, motivo per cui la sua affidabilità può risultare ridotta in scenari reali complessi. Tuttavia, in combinazione con altre metriche, può contribuire a fornire una stima più completa dello stato di nitidezza dell'immagine.

3

Definizione dei threshold

3.1 Calcolo del threshold

Le metriche introdotte nel capitolo precedente forniscono un valore numerico che quantifica il livello di sfocatura di un'immagine. Tuttavia, per poter utilizzare tali valori in modo decisionale, è necessario definire una soglia (*threshold*) che consenta di discriminare tra immagini nitide e immagini sfocate. In generale, un'immagine verrà classificata come sfocata se il valore della metrica supera una determinata soglia t , mentre verrà considerata accettabile (cioè sufficientemente nitida) se il valore rimane al di sotto di tale soglia. È importante sottolineare che ogni metrica definisce una propria scala di valori e, di conseguenza, richiede una soglia specifica. In altre parole, avremo valori distinti come $t_{fourier}$, t_{skew} , $t_{laplacian}$ e t_{canny} , ciascuno associato alla metrica corrispondente. Il problema della definizione del threshold non può essere risolto in modo globale, ma deve essere affrontato tenendo conto delle caratteristiche dell'infrastruttura e dei dati disponibili. In particolare, nel contesto considerato, il valore della soglia viene stimato a partire da più telecamere presenti nell'impianto. Sia N il numero di telecamere disponibili. Per ogni telecamera i (con $1 \leq i \leq N$) è possibile stimare un valore locale di soglia t_i , ottenuto analizzando le immagini acquisite da quella specifica telecamera. Il valore globale della soglia t viene quindi calcolato come media dei contributi delle singole telecamere:

$$t = \frac{1}{N} \sum_{i=1}^N t_i \quad (3.1)$$

In questo modo si assume che ogni telecamera contribuisca in modo equivalente alla definizione del threshold globale. Questa scelta permette di ottenere un valore robusto e rappresentativo dell'intero sistema. Per costruire il valore t_i è necessario analizzare più immagini provenienti dalla stessa telecamera. Sia n_i il numero di immagini associate alla telecamera i . Ogni immagine viene indicizzata come I_i^j , dove j indica il numero dell'immagine con $1 \leq j \leq n_i$. Per ogni immagine I_i^j si definisce una funzione parametrica $I_i^j(k)$, che rappresenta la stessa immagine sottoposta a un processo di sfocatura artificiale mediante un kernel di dimensione k . In particolare, $I_i^j(1)$

rappresenta l'immagine originale, mentre all'aumentare di k l'immagine risulta progressivamente più sfocata. La funzione $I_i^j(k)$ è definita solo per valori dispari di k , poiché il kernel utilizzato nella convoluzione deve avere un elemento centrale ben definito. Questo è necessario per garantire che l'operazione di convoluzione possa essere applicata correttamente su ogni pixel dell'immagine. Per ogni immagine I_i^j si individua un valore critico k_i^j , tale che:

- per kernel di dimensione fino a k_i^j , il sistema di riconoscimento del *plate* riesce ancora a decodificare correttamente il codice;
- per kernel di dimensione maggiore di k_i^j , il sistema fallisce in modo sistematico nel riconoscimento del codice.

In altre parole, k_i^j rappresenta il punto di transizione tra condizioni di riconoscimento affidabile e condizioni di fallimento dovute alla sfocatura. A partire da questo valore, si definisce il threshold locale dell'immagine come il valore di sfocatura associato alla prima condizione di fallimento, cioè:

$$t_i^j = \alpha_{I_i^j(k_i^j+1)} \quad (3.2)$$

dove α_ξ rappresenta il valore di *blur* calcolato sull'immagine ξ tramite la metrica scelta. Questo approccio consente di collegare direttamente il valore della metrica alla reale capacità del sistema di riconoscimento di funzionare correttamente. Una volta ottenuti tutti i valori t_i^j per una singola telecamera, il threshold associato alla telecamera i viene calcolato come media:

$$t_i = \frac{1}{n_i} \sum_{j=1}^{n_i} t_i^j \quad (3.3)$$

In alternativa alla media, è possibile utilizzare operatori più robusti come la mediana, nel caso in cui il dataset contenga valori anomali che potrebbero influenzare eccessivamente il risultato finale.

Infine, combinando i contributi di tutte le telecamere si ottiene il threshold globale associato a una specifica metrica m :

$$t^m = \frac{1}{N} \sum_{i=1}^N \left(\frac{1}{n_i} \sum_{j=1}^{n_i} \alpha_{I_i^j(k_i^j+1)}^m \right) \quad (3.4)$$

dove:

- m identifica la metrica utilizzata;
- α_ξ^m rappresenta il valore di sfocatura dell'immagine ξ calcolato con la metrica m ;
- t^m è il threshold finale associato alla metrica m .

Questo processo consente di ottenere una soglia coerente e adattata all'intero sistema, basata direttamente sul comportamento reale delle telecamere e sulle condizioni in cui il sistema di riconoscimento inizia a fallire.

3.2 Considerazioni sulla risoluzione delle immagini

Un aspetto rilevante nella definizione dei threshold riguarda la risoluzione delle immagini e, in particolare, la dimensione apparente del *plate* all'interno del frame. Le diverse telecamere dell'infrastruttura possono infatti essere installate in posizioni e con angolazioni differenti rispetto alle cisterne monitorate. Di conseguenza, pur avendo una risoluzione fissa, le immagini acquisite possono rappresentare il *plate* con dimensioni in pixel significativamente diverse da una telecamera all'altra. In alcuni casi il *plate* occupa una porzione ampia dell'immagine, tipicamente quando la telecamera è posizionata a distanza ridotta o con un'inquadratura ravvicinata. In altri casi, invece, il *plate* risulta più piccolo, ad esempio quando la telecamera si trova più distante o osserva la scena da un'angolazione più ampia. Questa differenza di scala ha un impatto diretto sulla sensibilità delle metriche di sfocatura. Infatti, immagini in cui il *plate* occupa un numero elevato di pixel tendono ad essere meno sensibili alla sfocatura: anche in presenza di un degrado significativo, il sistema di riconoscimento può ancora riuscire a decodificare correttamente il codice. Al contrario, quando il *plate* è più piccolo nell'immagine, anche una lieve sfocatura può compromettere in modo significativo la leggibilità del codice. Questo comporta una variazione implicita del valore di threshold associato a ciascuna telecamera. Se si definisce un threshold specifico per ogni singola telecamera, tale problema viene naturalmente compensato, poiché il valore t_i riflette direttamente le condizioni geometriche e ottiche della singola installazione. In questo caso, il threshold rappresenta semplicemente il livello massimo di sfocatura tollerabile prima che la pipeline di riconoscimento non sia più in grado di garantire risultati affidabili. Tuttavia, nel caso in cui si voglia definire un threshold globale valido per tutte le telecamere, è necessario introdurre una fase di normalizzazione per ridurre l'effetto dovuto alle differenze di scala del *plate* nelle varie immagini. Senza questa correzione, le telecamere che osservano il *plate* da vicino tenderebbero a produrre valori di threshold più elevati, mentre quelle con *plate* più piccoli contribuirebbero con valori più bassi, introducendo un bias nella stima complessiva. Per questo motivo, la pipeline di riconoscimento del *plate* prevede una fase preliminare di preprocessing in cui l'immagine viene ridimensionata in modo tale che il lato del *plate* assuma una dimensione standardizzata, tipicamente pari a circa 15 pixel. Questo processo è supportato da coefficienti di normalizzazione forniti dall'infrastruttura, che consentono di rendere confrontabili le immagini provenienti da telecamere diverse.

L'utilizzo di immagini ridimensionate presenta anche un vantaggio importante dal punto di vista delle metriche di sfocatura. Poiché i filtri utilizzati per simulare la sfocatura operano con kernel di dimensione fissa (ad esempio 3, 5, 7, ...), la normalizzazione della scala geometrica permette di rendere più coerente l'effetto della sfocatura sulle diverse immagini. In questo modo, le metriche risultano meno dipendenti dalla dimensione assoluta del *plate* e più sensibili alla reale perdita di nitidezza. Considerando quindi le immagini normalizzate anziché quelle originali, è possibile ottenere valori di threshold $t_1, t_2, \dots, t_N$ più omogenei tra le diverse telecamere. Questo consente di definire un valore globale t più stabile e rappresentativo, che descrive in modo più

accurato il punto in cui un'immagine può essere considerata effettivamente sfocata all'interno dell'intero sistema.

Valutazione e confronto delle metriche

Ogni metrica introdotta nei capitoli precedenti produce un insieme di valori di soglia t_i , uno per ciascuna telecamera dell'infrastruttura. A partire da questi valori locali viene poi definito un threshold globale t^m associato alla metrica m , ottenuto come media dei contributi provenienti dalle diverse telecamere. L'idea alla base della valutazione delle metriche è che una buona metrica debba fornire un comportamento coerente tra le diverse telecamere, ovvero valori di soglia il più possibile simili tra loro. In altre parole, se una metrica è stabile, i vari t_i dovrebbero risultare concentrati attorno ad un valore comune, indipendentemente dalla specifica telecamera o dalla sua configurazione. Per questo motivo, oltre al valore medio $\mu = t^m$, risulta particolarmente utile analizzare la dispersione dei valori t_i , misurata tramite la deviazione standard σ . Una bassa deviazione standard indica infatti che la metrica fornisce stime consistenti del threshold per tutte le telecamere, mentre una deviazione elevata suggerisce una forte dipendenza dalla singola configurazione della camera. Per rendere confrontabili i risultati tra metriche diverse, la deviazione standard viene normalizzata rispetto al valor medio, ottenendo il seguente indice adimensionale:

$$\sigma_{\text{norm}} = \frac{\sigma}{\mu} \quad (4.1)$$

Questo rapporto consente di confrontare in modo omogeneo metriche che operano su scale numeriche differenti e di valutare direttamente la stabilità relativa di ciascun approccio.

I risultati sperimentali ottenuti per le diverse metriche sono riportati nella tabella seguente.

Metrica	μ	σ	σ_{norm}
Laplacian	$1.2684 \cdot 10^{-1}$	$9.8223 \cdot 10^{-2}$	$7.7 \cdot 10^{-1}$
Canny	$1.0884 \cdot 10^{-3}$	$1.4378 \cdot 10^{-3}$	1.3
Jpgsize	$2.6709 \cdot 10^{-2}$	$1.1889 \cdot 10^{-2}$	$4.5 \cdot 10^{-1}$
Fourier	$6.2948 \cdot 10^{-1}$	$7.0088 \cdot 10^{-1}$	$1.1 \cdot 10^{-1}$
Skew	1.3705	$2.3715 \cdot 10^{-1}$	$1.7 \cdot 10^{-1}$

(4.2)

Dall'analisi dei risultati emerge chiaramente che le metriche basate sull'analisi dello spettro

delle frequenze, in particolare la metrica Fourier e quella basata sulla skewness, presentano una deviazione standard normalizzata significativamente più bassa rispetto alle altre. Questo indica che tali approcci producono threshold più stabili e coerenti tra le diverse telecamere, risultando quindi meno influenzati dalle specifiche condizioni di acquisizione. Le metriche basate sull'edge detection, come Laplacian e Canny, mostrano invece una maggiore variabilità tra le telecamere. In particolare, la metrica Canny presenta la deviazione standard normalizzata più elevata tra tutte quelle considerate. Questo comportamento può essere spiegato considerando la natura stessa dell'algoritmo di Canny. Essendo una pipeline articolata che include diverse fasi (filtraggio Gaussiano, calcolo del gradiente, soppressione dei non-massimi e sogliaatura), il risultato finale è particolarmente sensibile a variazioni locali dell'immagine. Differenze nella dimensione apparente del *plate*, nelle condizioni di illuminazione o nel livello di rumore possono influenzare in modo significativo il numero e la qualità dei bordi rilevati. Di conseguenza, il valore della varianza dell'immagine risultante tende a variare maggiormente tra telecamere differenti, generando una maggiore dispersione dei relativi threshold. Anche la metrica basata sulla dimensione dei file JPEG presenta una variabilità non trascurabile, poiché risente non solo della nitidezza ma anche di altri fattori strutturali dell'immagine, come la complessità cromatica e la distribuzione delle texture. Questo la rende meno stabile rispetto alle metriche basate su trasformazioni più direttamente legate al contenuto frequenziale o strutturale dell'immagine.

Nel complesso, i risultati suggeriscono che le metriche basate sull'analisi delle frequenze risultano più robuste nel contesto considerato, in quanto riescono a fornire stime del threshold più consistenti tra le diverse telecamere dell'infrastruttura.




Figura 4.1: Confronto delle deviazioni standard normalizzate dei valori t_i per le diverse metriche considerate.

Conclusioni e considerazioni finali

Nel presente lavoro è stato sviluppato un approccio per la rilevazione automatica dello stato di pulizia dell'obiettivo delle telecamere, basato sull'analisi del livello di sfocatura delle immagini acquisite. L'idea generale è quella di utilizzare un indice numerico, il cosiddetto *blur value* α , per stimare la qualità dell'immagine e, indirettamente, individuare la presenza di sporco sull'obiettivo. A partire dalle metriche introdotte nei capitoli precedenti, ogni immagine può essere associata a un valore α che descrive il suo grado di nitidezza. Per rendere tale informazione utilizzabile in modo decisionale, è stato introdotto un valore di soglia t^m (dipendente dalla metrica scelta), che rappresenta il confine tra immagini considerate accettabili e immagini considerate sfocate. Sia J^i un'immagine acquisita dalla telecamera i . Il problema della classificazione può essere quindi formulato come un semplice confronto tra il valore della metrica e il threshold associato:

$$\text{dirtTest}(J^i) = \begin{cases} \text{True} & \alpha_{J^i}^m > t^m \\ \text{False} & \text{else} \end{cases} \quad (5.1)$$

In questo contesto, il valore *True* indica la presenza di una condizione anomala, tipicamente associata a un'immagine eccessivamente sfocata e quindi potenzialmente causata da sporco sull'obiettivo. Al contrario, il valore *False* indica che l'immagine rientra nelle condizioni operative normali. Oltre alla soglia globale t^m , è possibile adottare una strategia più fine che tiene conto delle differenze tra le singole telecamere. In questo caso, viene utilizzato il threshold locale t_i , specifico per ciascuna telecamera, ottenuto durante la fase di calibrazione:

$$\text{dirtTest}(J^i) = \begin{cases} \text{True} & \alpha_{J^i}^m > t_i \\ \text{False} & \text{else} \end{cases} \quad (5.2)$$

Questo secondo approccio consente di adattare la decisione alle caratteristiche specifiche di ogni punto di ripresa, riducendo l'effetto delle differenze di installazione e migliorando la coerenza della classificazione.

Nel complesso, il lavoro ha mostrato come sia possibile costruire un sistema completo per il monitoraggio dello stato delle telecamere utilizzando esclusivamente l'analisi delle immagini e senza la necessità di sensori aggiuntivi. Sono state analizzate diverse famiglie di metriche per la stima del *blur value*, basate sia sul dominio delle frequenze che su tecniche di *edge detection*, oltre ad alcune soluzioni alternative più semplici. L'integrazione di queste metriche con un processo di calibrazione basato sui dati reali dell'infrastruttura ha permesso di definire soglie operative coerenti e utilizzabili in un contesto industriale. In questo modo, il sistema non si limita a rilevare la sfocatura, ma può essere impiegato come strumento di supporto alla manutenzione preventiva. In particolare, la possibilità di individuare in anticipo il degrado delle condizioni dell'obiettivo consente di intervenire prima che la qualità delle immagini comprometta il funzionamento della pipeline di riconoscimento dei codici sui *plate*. Questo si traduce in una maggiore affidabilità complessiva del sistema e in una riduzione dei tempi di inattività dovuti a problemi non immediatamente evidenti.

Bibliografia

- [1] CCITT. *T.81 – DIGITAL COMPRESSION AND CODING OF CONTINUOUS-TONE STILL IMAGES – REQUIREMENTS AND GUIDELINES*. International Telecommunication Union, 1992.
- [2] N. Balakrishnan NL. Johnson, S. Kotz. *Continuous Univariate Distributions. Vol. 1 (2 ed.)*. Wiley, 1994.
- [3] L. Shapiro R. Haralick. *Computer and Robot Vision pp 346-351*. Addison-Wesley, 1992.
- [4] Zhang Wei Sun Lining Rong Weibin, Li Zhanjing. *An improved Canny edge detection algorithm, pp 577–582*. IEEE, 2014.
- [5] Irwin Sobel. *History and Definition of the Sobel Operator*. 2014.
- [6] Gilbert Strang. *Wavelets*. American Scientist, Volume 82, Issue 3, 1994.